

Ley de los Grandes Números

Mariela Sued, Jemina García y Ana M. Bianco

03 junio 2020

Un caso especial: muestra aleatoria (m.a.)

Un caso especial: muestra aleatoria (m.a.)

1. Repetimos un experimento muchas veces en idénticas condiciones y de manera independiente.
2. X_i : resultado de la i -ésima repetición.
3. $X_i \sim F$: tienen todas la misma distribución porque repetimos en idénticas condiciones.
4. X_1, \dots, X_n son independientes (estadísticamente) por construcción: las repeticiones se realizan de manera independiente (en sentido de la vida).

Un caso especial: muestra aleatoria (m.a.)

1. Repetimos un experimento muchas veces en idénticas condiciones y de manera independiente.
2. X_i : resultado de la i -ésima repetición.
3. $X_i \sim F$: tienen todas la misma distribución porque repetimos en idénticas condiciones.
4. X_1, \dots, X_n son independientes (estadísticamente) por construcción: las repeticiones se realizan de manera independiente (en sentido de la vida).

Luego, $X_i \sim F$ para todo i , y por consiguiente:

- ▶ $\mathbb{P}(X_i \leq t) = \mathbb{P}(X_j \leq t) = \mathbb{P}(X_1 \leq t)$
- ▶ $\mathbb{E}[X_i] = \mathbb{E}[X_j] = \mathbb{E}[X_1]$
- ▶ $\mathbb{V}(X_i) = \mathbb{V}(X_j) = \mathbb{V}(X_1)$
- ▶ Dicho de otra forma:
 $\text{mongo}(X_i) = \text{mongo}(X_j) = \text{mongo}(X_1)$.

Un caso especial: muestra aleatoria (m.a.)

1. Repetimos un experimento muchas veces en idénticas condiciones y de manera independiente.
2. X_i : resultado de la i -ésima repetición.
3. $X_i \sim F$: tienen todas la misma distribución porque repetimos en idénticas condiciones.
4. X_1, \dots, X_n son independientes (estadísticamente) por construcción: las repeticiones se realizan de manera independiente (en sentido de la vida).

Luego, $X_i \sim F$ para todo i , y por consiguiente:

- ▶ $\mathbb{P}(X_i \leq t) = \mathbb{P}(X_j \leq t) = \mathbb{P}(X_1 \leq t)$
- ▶ $\mathbb{E}[X_i] = \mathbb{E}[X_j] = \mathbb{E}[X_1]$
- ▶ $\mathbb{V}(X_i) = \mathbb{V}(X_j) = \mathbb{V}(X_1)$
- ▶ Dicho de otra forma:
 $\text{mongo}(X_i) = \text{mongo}(X_j) = \text{mongo}(X_1)$.

Muestra (aleatoria) o variables i.i.d.

X_1, \dots, X_n son una muestra aleatoria si son v. a. independientes, idénticamente distribuídas.

$$X_1, \dots, X_n, \text{ i.i.d.}$$

En tal caso, $X_i \sim F$ para todo i , y por consiguiente,

► $\text{mongo}(X_i) = \text{mongo}(X_j) = \text{mongo}(X_1).$

Muestra (aleatoria) o variables i.i.d.

¿Qué relación guarda la muestra con nuestros datos?

Una noche en el casino: Ruleta



¿Apostamos una fichita?

- ▶ Si acierto: me devuelven 36 fichas ($35 + \text{la mía}$)
- ▶ Si pierdo: se llevan mi ficha

¿Apostamos una fichita?

- ▶ Si acierto: me devuelven 36 fichas ($35 + \text{la mía}$)
- ▶ Si pierdo: se llevan mi ficha

Dicho de otro modo:

- ▶ Si acierto: Gano 35
- ▶ Si pierdo: Gano -1

Una larga noche ...

[1] - 1 - 1 35 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1
[20] - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 35 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1
[39] - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1
[58] - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1
[77] - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1
[96] - 1 - 1 - 1 - 1 35 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1
[115] - 1 - 1 - 1 - 1 - 1 - 1 35 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1
[134] - 1 - 1 - 1 - 1 - 1 - 1 - 1 35 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1
[153] - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1 - 1

estos son los resultados...

...ésta es la historia de lo que pasó

... pensemos. . .

Podríamos decir que los datos que les doy son

- el resultado o lo que observamos en cada jugada:

$$x_1 = -1, x_2 = -1, x_3 = 35, \dots, x_{27} = -1, \dots, x_{28} = 35, x_{29} = -1$$

Estos datos, ¿son los resultados o las observaciones de qué?

... pensemos. ...

- ▶ $x_1 = -1$ es el valor observado de la *ganancia obtenida en la primera jugada* o sea de la v.a. X_1

... pensemos. ...

- ▶ $x_1 = -1$ es el valor observado de la *ganancia obtenida en la primera jugada* o sea de la v.a. X_1
- ▶ $x_2 = -1$ es el valor observado de la *ganancia obtenida en la segunda jugada* o de sea la v.a. X_2

... pensemos. . .

- ▶ $x_1 = -1$ es el valor observado de la *ganancia obtenida en la primera jugada* o sea de la v.a. X_1
- ▶ $x_2 = -1$ es el valor observado de la *ganancia obtenida en la segunda jugada* o de sea la v.a. X_2
- ▶ $x_3 = 35$ es el valor observado de la *ganancia obtenida en la tercera jugada* o de sea la v.a. X_3
- ▶
- ▶ $x_i = -1$ es el valor observado de la *ganancia obtenida en la i -ésima jugada* o sea de la v.a. X_i
- ▶
- ▶ $X_1, X_2, \dots, X_i \dots, X_n$ son variables aleatorias idénticamente distribuidas

... pensemos. ...

- ▶ $x_1 = -1$ es el valor observado de la *ganancia obtenida en la primera jugada* o sea de la v.a. X_1
- ▶ $x_2 = -1$ es el valor observado de la *ganancia obtenida en la segunda jugada* o de sea la v.a. X_2
- ▶ $x_3 = 35$ es el valor observado de la *ganancia obtenida en la tercera jugada* o de sea la v.a. X_3
- ▶
- ▶ $x_i = -1$ es el valor observado de la *ganancia obtenida en la i -ésima jugada* o sea de la v.a. X_i
- ▶
- ▶ $X_1, X_2, \dots, X_i, \dots, X_n$ son variables aleatorias idénticamente distribuidas
- ▶ Por las condiciones de *este experimento* las X_i resultan independientes.

$$X_1, X_2, \dots, X_i, \dots, X_n \text{ i.i.d.}$$

Para pensar: ¿Siempre es así?

Supongamos que en una caja tenemos 100 bolitas: 90 blancas y 10 rojas. Consideremos las siguientes dos situaciones:

- ▶ extraemos 5 bolitas **con reposición**. Para cada extracción definimos $1 \leq i \leq 5$:

$$X_i = \begin{cases} 1 & \text{si la } i\text{-ésima bolita extraída es roja} \\ 0 & \text{si la } i\text{-ésima bolita extraída es blanca} \end{cases}$$

¿Son las X_i v.a. i.i.d.?

Para pensar: ¿Siempre es así?

Supongamos que en una caja tenemos 100 bolitas: 90 blancas y 10 rojas. Consideremos las siguientes dos situaciones:

- ▶ extraemos 5 bolitas **con reposición**. Para cada extracción definimos $1 \leq i \leq 5$:

$$X_i = \begin{cases} 1 & \text{si la } i\text{-ésima bolita extraída es roja} \\ 0 & \text{si la } i\text{-ésima bolita extraída es blanca} \end{cases}$$

¿Son las X_i v.a. i.i.d.?

- ▶ extraemos 5 bolitas **sin reposición**. Para cada extracción definimos $1 \leq i \leq 5$:

$$Y_i = \begin{cases} 1 & \text{si la } i\text{-ésima bolita extraída es roja} \\ 0 & \text{si la } i\text{-ésima bolita extraída es blanca} \end{cases}$$

¿Son las Y_i v.a. independientes?

Para seguir pensando...

¿Qué relación guarda todo esto con nuestras simulaciones?

Para seguir pensando...

¿Qué relación guarda todo esto con nuestras simulaciones?

¿Qué estamos haciendo con el comando `runif(10,0,1)`?

Volviendo a la muestra

X_1, \dots, X_n **i.i.d.**, con $\mathbb{E}[X_i] = \mu$ y $\mathbb{V}[X_i] = \sigma^2$, para todo i .

- $S_n = \sum_{i=1}^n X_i \quad \implies \mathbb{E}[S_n] = n \mu \quad \text{y} \quad \mathbb{V}[S_n] = n \sigma^2$

- $\bar{X} = \bar{X}_n = \frac{\sum_{i=1}^n X_i}{n} \quad \implies \mathbb{E}[\bar{X}_n] = \mu \quad \text{y} \quad \mathbb{V}[\bar{X}_n] = \frac{\sigma^2}{n}$

Caso Particular: Suma y Promedio de normales

- ▶ $(X_i)_{1 \leq i \leq n}$ i.i.d., $X_i \sim \mathcal{N}(\mu, \sigma^2)$
- ▶ Suma: $S_n = X_1 + \dots + X_n \sim ?$
- ▶ Promedio: $\bar{X}_n = \frac{1}{n}(X_1 + \dots + X_n) \sim ?$

Vayamos a la lista de tareas

Simulemos:

Estudiaremos la distribución de S_n y de \bar{X}_n de variables X_1, \dots, X_n i.i.d. $\mathcal{N}(\mu, \sigma^2)$.

Para ello, fijado n , generaremos datos correspondientes a una muestra X_1, \dots, X_n i.i.d. de variables aleatorias distribuidas como X , con una distribución $\mathcal{N}(5, 4)$ y luego calcularemos la suma y el promedio de cada conjunto de datos.

Repetimos este procedimiento $Nrep = 1000$ veces. A partir de las $Nrep = 1000$ replicaciones realizaremos un histograma con las sumas y los promedios generados, para obtener una aproximación de la densidad de S_n y de \bar{X}_n .


Para ello, fijado n , generaremos datos correspondientes a una muestra X_1, \dots, X_n i.i.d. de variables aleatorias distribuidas como $X \sim \mathcal{N}(5, 4)$, para $n = 1, 2, 5, 10, 25$. Luego, haremos un histograma para luego tratar de responder a qué densidad se parece el histograma obtenido y superponerle una densidad adecuada.

$n = 1$

- Consideramos $n = 1$ en cuyo caso la variable coincide con la suma y el promedio.

Generamos entonces $N_{rep} = 1000$ datos correspondientes a $X_1 \sim \mathcal{N}(5, 4)$ y luego hacemos un histograma.

```
Nrep<- 1000  
set.seed(123)  
X1<-rnorm(Nrep,mean=5,sd=2)    # Genero normales  
hist(X1,freq=F)  
curve(dnorm(x, mean=5,sd=2), add=T, col="blue")
```



$$n = 2$$

- Consideramos $n = 2$ y las variables



$$S_2 = X_1 + X_2 \quad \text{y} \quad \bar{X}_2 = \frac{X_1 + X_2}{2}.$$

Generamos $n = 2$ datos (independientes) correspondientes a variables aleatorias con distribución $\mathcal{N}(5, 4)$ y computamos la suma y el promedio. Replicamos $Nrep = 1000$ veces y realizamos los dos histograma con los $Nrep = 1000$ promedios obtenidos.

```
Nrep<- 1000  
X1<-rnorm(Nrep,mean=5,sd=2)    # Genero normales  
X2<-rnorm(Nrep,mean=5,sd=2)    # Genero normales  
suma2<- X1+X2  
prom2<- suma2/2
```

Graficamos

```
hist(suma2,freq=F)  
hist(prom2,freq=F)
```





Otra forma

```
ene=2  
matriz2<-matrix(rnorm(1000*ene,mean=5,sd=2),nrow=ene, ncol=1000,byrow=T)  
suma2<-apply(matriz2,2,sum)  
prom2<-apply(matriz2,2,mean)
```

Grafico

```
hist(suma2,freq=F)  
hist(prom2,freq=F)
```



Suma y Promedio de normales

X_1, \dots, X_n i.i.d., $X_i \sim \mathcal{N}(\mu, \sigma^2)$

- Suma: $S_n = \sum_{i=1}^n X_i \sim \mathcal{N}(n\mu, n\sigma^2)$


Suma y Promedio de normales

X_1, \dots, X_n i.i.d., $X_i \sim \mathcal{N}(\mu, \sigma^2)$

- Suma: $S_n = \sum_{i=1}^n X_i \sim \mathcal{N}(n\mu, n\sigma^2)$

- Promedio: $\bar{X}_n = \frac{\sum_{i=1}^n X_i}{n} \sim \mathcal{N}(\mu, \sigma^2/n)$

Comparando las densidades $N(\mu, \sigma^2/n)$



Suma y Promedio de normales

$$X_1, \dots, X_n \text{ i.i.d., } X_i \sim \mathcal{N}(\mu, \sigma^2)$$

- Suma: $S_n = \sum_{i=1}^n X_i \sim \mathcal{N}(n\mu, n\sigma^2)$

Suma y Promedio de normales

X_1, \dots, X_n i.i.d., $X_i \sim \mathcal{N}(\mu, \sigma^2)$

- Suma: $S_n = \sum_{i=1}^n X_i \sim \mathcal{N}(n\mu, n\sigma^2)$

- Promedio: $\bar{X}_n = \frac{\sum_{i=1}^n X_i}{n} \sim \mathcal{N}(\mu, \sigma^2/n)$

$$\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) = 2(1 - \Phi(\varepsilon\sqrt{n}/\sigma))$$

donde $\phi(z) = \mathbb{P}(Z \leq z)$, $Z \sim \mathcal{N}(0, 1)$

En otras palabras, estamos viendo que

Si X_1, \dots, X_n i.i.d., $X_i \sim \mathcal{N}(\mu, \sigma^2)$, para todo $\varepsilon > 0$, tenemos que

$$\mathbb{P}\left(|\bar{X}_n - \mu| > \varepsilon\right) = 2 \left(1 - \phi\left(\frac{\varepsilon \cdot \sqrt{n}}{\sigma}\right)\right).$$

Luego

$$\mathbb{P}\left(|\bar{X}_n - \mu| > \varepsilon\right) \xrightarrow{n \rightarrow \infty} 0$$



$$\mathbb{P}\left(|\bar{X}_n - \mu| \leq \varepsilon\right) \xrightarrow{n \rightarrow \infty} 1$$

¿Qué pasará con otras distribuciones?

Simulemos

Generaremos muestras aleatorias de una distribución $\mathcal{U}(0, 1)$, de tamaño cada vez mayor, y calcularemos las medias muestrales. Comprobaremos si estos promedios muestrales se acercan al valor verdadero de la media cuando el tamaño muestral crece.

1. Probamos primero con una distribución $\mathcal{U}(0, 2)$. Indique cuál es el valor verdadero de la media μ .
2. Generamos una muestra de tamaño $N_{rep} = 1000$ y para cada n entre 1 y 1000 calculemos el promedio de las primeras n observaciones. Realizamos un scatterplot de n vs. los promedios obtenidos. Incluimos una línea horizontal en el valor de y correspondiente a la verdadera media μ .
3. Repetimos comenzando con otra semilla y superpongamos el nuevo gráfico utilizando un color diferente. Comparamos los gráficos obtenidos. ¿Qué podemos concluir?



¿Qué pasa con otras distribuciones?

Desigualdad de Tchebycheff

Sea W una v.a. con media $\mathbb{E}(W) = \mu_w$ y $V(W) = \sigma_w^2$. Luego, $\varepsilon > 0$

$$\mathbb{P}(|W - \mu_w| \geq \varepsilon) \leq \frac{\sigma_w^2}{\varepsilon^2}$$

¿Qué pasa con otras distribuciones?

Desigualdad de Tchebycheff

Sea W una v.a. con media $\mathbb{E}(W) = \mu_w$ y $V(W) = \sigma_w^2$. Luego, $\varepsilon > 0$

$$\mathbb{P}(|W - \mu_w| \geq \varepsilon) \leq \frac{\sigma_w^2}{\varepsilon^2}$$

Tomando $\varepsilon = k\sigma_w$,

$$\mathbb{P}(|W - \mu_w| \geq k \sigma_w) \leq \frac{\sigma_w^2}{k^2 \sigma_w^2} = \frac{1}{k^2}$$

¿Qué pasa con otras distribuciones?

Desigualdad de Tchebycheff

Sea W una v.a. con media $\mathbb{E}(W) = \mu_w$ y $V(W) = \sigma_w^2$. Luego, $\varepsilon > 0$

$$\mathbb{P}(|W - \mu_w| \geq \varepsilon) \leq \frac{\sigma_w^2}{\varepsilon^2}$$

Tomando $\varepsilon = k\sigma_w$,

$$\mathbb{P}(|W - \mu_w| \geq k \sigma_w) \leq \frac{\sigma_w^2}{k^2 \sigma_w^2} = \frac{1}{k^2}$$

En particular, para $k = 1, 2, 3$, obtenemos las las siguientes cotas:

$$\begin{aligned}\mathbb{P}(|W - \mu_w| \geq \sigma_w) &\leq 1, \\ \mathbb{P}(|W - \mu_w| \geq 2\sigma_w) &\leq \frac{1}{4}, \\ \mathbb{P}(|W - \mu_w| \geq 3\sigma_w) &\leq \frac{1}{9}\end{aligned}$$

Desigualdad de Tchebycheff aplicada a promedios

- ▶ $(X_i)_{i \geq 1}$ iid, $\mathbb{E}(X_i) = \mu$, $\mathbb{V}(X_i) = \sigma^2$.

- ▶ Promedio :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \sim ?$$

- ▶ Esperanza y Varianza del promedio

$$\mu_{\bar{X}_n} = \mathbb{E}(\bar{X}_n) = \mu, \quad \sigma_{\bar{X}_n}^2 = V(\bar{X}_n) = \frac{\sigma^2}{n}.$$

- ▶ Tchebycheff dice:

$$\mathbb{P}(|\bar{X}_n - \mu_{\bar{X}_n}| \geq \varepsilon) \leq \frac{\sigma_{\bar{X}_n}^2}{\varepsilon^2}$$

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2/n}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}$$

Teorema: Ley de los Grandes Números (LGN)

Sean $(X_i)_{i \geq 1}$ i.i.d., con $\mathbb{E}[X_i] = \mu$ y $\mathbb{V}[X_i] = \sigma^2$, para todo i .
entonces para todo $\varepsilon > 0$ vale que

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) = 0.$$

Teorema: Ley de los Grandes Números (LGN)

Sean $(X_i)_{i \geq 1}$ i.i.d., con $\mathbb{E}[X_i] = \mu$ y $\mathbb{V}[X_i] = \sigma^2$, para todo i .
entonces para todo $\varepsilon > 0$ vale que

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) = 0.$$

Es decir, el promedio converge a μ en probabilidad:

$$\bar{X}_n \rightarrow \mu \text{ en probabilidad}$$

Ley de los Grandes Números

Demostración: Tchebycheff prueba que

$$\mathbb{P}(|W - \mathbb{E}[W]| \geq \varepsilon) \leq \frac{\mathbb{V}[W]}{\varepsilon^2}$$

Vamos a invocar la Desigualdad de Tchebicheff, pero con $W = \bar{X}_n$.
En tal caso,

$$\mu_{\bar{X}_n} = \mathbb{E}(\bar{X}_n) = \mu$$

$$\sigma_{\bar{X}_n}^2 = \mathbb{V}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

Tenemos entonces que

$$0 \leq \mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) = \mathbb{P}(|\bar{X}_n - \mu_{\bar{X}_n}| > \varepsilon) \leq \frac{\mathbb{V}(\bar{X}_n)}{\varepsilon^2} = \frac{1}{\varepsilon^2} \frac{\sigma^2}{n} \rightarrow 0$$

L.G.N. aplicada a Variables Bernoulli

\mathbb{E} : experimento, A evento, $p = P(A)$

Repetimos en forma independiente \mathbb{E} $n \gg$ (muchas veces!!)

X_i : 1 si ocurre A 0 si no ocurre A

- ▶ $X_i \sim \mathcal{B}(1, p)$
- ▶ $\mathbb{E}(X_i) = p$, $\mathbb{V}(X_i) = p(1 - p)$.
- ▶ \overline{X}_n es la frecuencia relativa de éxitos en las n repeticiones.

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\overline{X}_n - p| > \varepsilon) = 0.$$

L.G.N. aplicada a Variables Bernoulli

\mathbb{E} : experimento, A evento, $p = P(A)$

Repetimos en forma independiente \mathbb{E} $n \gg \gg$ (muchas veces!!)

X_i : 1 si ocurre A 0 si no ocurre A

- ▶ $X_i \sim \mathcal{B}(1, p)$
- ▶ $\mathbb{E}(X_i) = p$, $\mathbb{V}(X_i) = p(1 - p)$.
- ▶ \overline{X}_n es la frecuencia relativa de éxitos en las n repeticiones.

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\overline{X}_n - p| > \varepsilon) = 0.$$

$$\mathbb{P}(|\overline{X}_n - p| \geq \varepsilon) \leq \frac{p(1-p)}{n\varepsilon^2} \leq \frac{1/4}{n\varepsilon^2}$$

L.G.N. aplicada a Variables Bernoulli

\mathbb{E} : experimento, A evento, $p = P(A)$

Repetimos en forma independiente \mathbb{E} $n \gg \gg$ (muchas veces!!)

X_i : 1 si ocurre A 0 si no ocurre A

- ▶ $X_i \sim \mathcal{B}(1, p)$
- ▶ $\mathbb{E}(X_i) = p$, $\mathbb{V}(X_i) = p(1 - p)$.
- ▶ \bar{X}_n es la frecuencia relativa de éxitos en las n repeticiones.

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - p| > \varepsilon) = 0.$$

$$\mathbb{P}(|\bar{X}_n - p| \geq \varepsilon) \leq \frac{p(1-p)}{n\varepsilon^2} \leq \frac{1/4}{n\varepsilon^2}$$

$\bar{X}_n \rightarrow p$ en probabilidad

Con una mirada estadística.... utilizamos la Ley de los Grandes
Números para Estimación

Variables Bernoulli

- $X_i \sim \mathcal{B}(1, p)$, i.i.d.
- $\mathbb{E}(X_i) = p$, $\mathbb{V}(X_i) = p(1 - p)$
- Por la Ley de los Grandes Números

$$\overline{X}_n \rightarrow \mathbb{E}(X_1) = p \quad \text{en probabilidad}$$

Variables Bernoulli

- $X_i \sim \mathcal{B}(1, p)$, i.i.d.
- $\mathbb{E}(X_i) = p$, $\mathbb{V}(X_i) = p(1 - p)$
- Por la Ley de los Grandes Números

$$\overline{X}_n \rightarrow \mathbb{E}(X_1) = p \quad \text{en probabilidad}$$

- En tal caso, definimos

$$\widehat{p} = \widehat{p}_n = \overline{X}_n$$

- Propiedades de \widehat{p}_n :
 - $\mathbb{E}(\widehat{p}_n) = p$
 - $\widehat{p}_n \rightarrow p$ en probabilidad.

Estimación de Probabilidades.

- $(X_i)_{i \geq 1}$, i.i.d. $X_i \sim F$.
- Nos interesa estimar $\mathbb{P}(X \in A)$.
- Definimos

$$Y_i = I_{X_i \in A} = I_A(X_i)$$

- $Y_i \sim \mathcal{B}(1, p)$, con

$$p = \mathbb{E}(Y_1) = \mathbb{P}(Y_1 = 1) = \mathbb{P}(X_1 \in A)$$

- Por la Ley de los Grandes Números (caso Bernoulli)

$$\bar{Y}_n \rightarrow \mathbb{E}(Y_1) = \mathbb{P}(X_1 \in A) \quad \text{en probabilidad}$$

- Es decir,

$$\frac{1}{n} \sum_{i=1}^n I_{\{X_i \in A\}} \longrightarrow \mathbb{P}(X_1 \in A) \quad \text{en probabilidad}$$

Demostramos que la frecuencia relativa converge a la probabilidad.

Estimación de la Esperanza

- $(X_i)_{i \geq 1}$, i.i.d. $X_i \sim F$.
- $\mathbb{E}(X_i) = \mu$, $\mathbb{V}(X_i) = \sigma^2$
- Por la Ley de los Grandes Números

$$\overline{X}_n \rightarrow \mathbb{E}(X_1) = \mu \quad \text{en probabilidad}$$

- En tal caso, definimos

$$\hat{\mu} = \hat{\mu}_n = \overline{X}_n$$

- Propiedades de $\hat{\mu}_n$:
 - $\mathbb{E}(\hat{\mu}_n) = \mu$
 - $\hat{\mu}_n \rightarrow \mu$ en probabilidad.

Estimación de Probabilidades - Ejemplo

- $(X_i)_{i \geq 1}$, i.i.d. $X_i \sim F$.
- Nos interesa estimar $F(3) = \mathbb{P}(X \leq 3)$.
- Definimos

$$Y_i = I_{\{X_i \leq 3\}} = I_{(-\infty, 3]}(X_i)$$

- $Y_i \sim \mathcal{B}(1, p)$, con

$$p = \mathbb{E}(Y_1) = \mathbb{P}(Y_1 = 1) = \mathbb{P}(X_1 \leq 3) = F(3)$$

- Por la Ley de los Grandes Números (caso Bernoulli)

$$\bar{Y}_n \rightarrow \mathbb{E}(Y_1) = F(3) \quad \text{en probabilidad}$$

- En tal caso, definimos

$$\hat{F}(3) = \hat{F}_n(3) = \bar{Y}_n = \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq 3\}}$$

Estimación de $F(t)$

- $(X_i)_{i \geq 1}$, i.i.d. $X_i \sim F$.
- Nos interesa estimar $F(t) = \mathbb{P}(X \leq t)$.
- Definimos

$$Y_i = I_{X_i \leq t} = I_{(-\infty, t]}(X_i)$$

- $Y_i \sim \mathcal{B}(1, p)$, con

$$p = \mathbb{E}(Y_1) = \mathbb{P}(Y_1 = 1) = \mathbb{P}(X_1 \leq t) = F(t)$$

- Por la Ley de los Grandes Números (caso Bernoulli)

$$\overline{Y}_n \rightarrow \mathbb{E}(Y_1) = F(t) \quad \text{en probabilidad}$$

- En tal caso, definimos

$$\widehat{F}(t) = \widehat{F}_n(t) = \overline{Y}_n = \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq t\}}$$

LA empírica

La LGN demuestra que la frecuencia relativa converge a la probabilidad.

$$(X_i)_{i \geq 1} \text{ i.i.d., } X_i \sim F$$

$$\text{LGN: } \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq 3\}} \xrightarrow{p} \mathbb{E}(I_{\{X_1 \leq 3\}}) = \mathbb{P}(X_1 \leq 3) = F(3).$$

LA empírica

La LGN demuestra que la frecuencia relativa converge a la probabilidad.

$$(X_i)_{i \geq 1} \text{ i.i.d., } X_i \sim F$$

$$\text{LGN: } \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq 3\}} \xrightarrow{p} \mathbb{E}(I_{\{X_1 \leq 3\}}) = \mathbb{P}(X_1 \leq 3) = F(3).$$

$$\hat{F}_n(3) := \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq 3\}}$$

LA empírica

La LGN demuestra que la frecuencia relativa converge a la probabilidad.

$$(X_i)_{i \geq 1} \text{ i.i.d., } X_i \sim F$$

$$\text{LGN: } \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq 3\}} \xrightarrow{p} \mathbb{E}(I_{\{X_1 \leq 3\}}) = \mathbb{P}(X_1 \leq 3) = F(3).$$

$$\hat{F}_n(3) := \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq 3\}}$$

$$\hat{F}_n(t) := \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq t\}}$$

LA empírica

La LGN demuestra que la frecuencia relativa converge a la probabilidad.

$$(X_i)_{i \geq 1} \text{ i.i.d., } X_i \sim F$$

$$\text{LGN: } \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq 3\}} \xrightarrow{p} \mathbb{E}(I_{\{X_1 \leq 3\}}) = \mathbb{P}(X_1 \leq 3) = F(3).$$

$$\hat{F}_n(3) := \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq 3\}}$$

$$\hat{F}_n(t) := \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq t\}}$$

$$\text{LGN: } \hat{F}_n(t) = \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq t\}} \xrightarrow{p} \mathbb{E}(I_{\{X_1 \leq t\}}) = \mathbb{P}(X_1 \leq t) = F(t).$$

LGN y una vuelta más de rosca....

- Promedio de mongo converge a esperanza de mongo:

$$\frac{1}{n} \sum_{i=1}^n \star_i \xrightarrow{p} \mathbb{E}(\star)$$

- Ejemplo:

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{p} \mathbb{E}(X_1^2)$$

LGN y una vuelta más de rosca....

- Promedio de mongo converge a esperanza de mongo:

$$\frac{1}{n} \sum_{i=1}^n \star_i \xrightarrow{p} \mathbb{E}(\star)$$

- Ejemplo:

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{p} \mathbb{E}(X_1^2)$$

- Funciones g continuas preservan convergencia en probabilidad.

$$g \left(\frac{1}{n} \sum_{i=1}^n \star_i \right) \xrightarrow{p} g(\mathbb{E}(\star))$$

- Ejemplo:

$$(\overline{X}_n)^2 \xrightarrow{p} \mu^2, \quad \mu = \mathbb{E}(X_1)$$

Estimando $\sigma^2 = \mathbb{V}(X) = \mathbb{E}(X^2) - \mu^2 = \mathbb{E}\{(X - \mu)^2\}$

- Muestra: X_1, \dots, X_n i.i.d. donde $X_i \sim X$

Estimando $\sigma^2 = \mathbb{V}(X) = \mathbb{E}(X^2) - \mu^2 = \mathbb{E}\{(X - \mu)^2\}$

- Muestra: X_1, \dots, X_n i.i.d. donde $X_i \sim X$
- ESTIMADOR : cuenta hecha con la muestra

$$\widehat{\sigma^2}_n = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\overline{X}_n)^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

- ESTIMACION: Valor del estimador al utilizar mis datos.
- Consistencia: el estimador converge a lo que queremos estimar:

$$\widehat{\sigma^2}_n = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\overline{X}_n)^2 \xrightarrow{p} E(X^2) - \mu^2 = \mathbb{V}(X)$$

Estimando $\sigma^2 = \mathbb{V}(X)$ y σ - OTRA VERSION

- Muestra: X_1, \dots, X_n i.i.d., $X_i \sim F$.
- ESTIMADOR : cuenta hecha con la muestra

$$S^2 = S_n^2 = \frac{n}{n-1} \widehat{\sigma_n^2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Estimando $\sigma^2 = \mathbb{V}(X)$ y σ - OTRA VERSION

- Muestra: X_1, \dots, X_n i.i.d., $X_i \sim F$.
- ESTIMADOR : cuenta hecha con la muestra

$$S^2 = S_n^2 = \frac{n}{n-1} \widehat{\sigma_n^2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

- ESTIMACION: Valor del estimador al utilizar mis datos.
- En R `var(datos)`, `sd(datos)`
- Consistencia: el estimador converge a lo que queremos estimar:

$$S_n^2 = \frac{n}{n-1} \widehat{\sigma_n^2} \xrightarrow{p} \sigma^2, \quad S_n = \sqrt{S_n^2} \xrightarrow{p} \sigma$$